Sistemas de Big Data · Sesión 04 · 20 alumnos · 5 grupos de 4

Reto: extraer, transformar y contar qué habéis hecho

Tenéis 60 minutos. Luego cada grupo presenta en 4 minutos: de dónde sale el dato, una transformación y para qué serviría.

Papeles

Se reparten al empezar y no se cambian. Los cuatro nombres van en la ficha.

Papel	Durante los 60 minutos
Fuente	Descarga el CSV desde el enlace del grupo y anota organismo, licencia y URL.
Carga	Lo abre con la chuleta. Anota filas, columnas, tipos y nulos.
Transformación	Hace tres cambios útiles: filtrar, convertir un tipo o quitar nulos, y resumir u ordenar.
Cierre	Rellena la ficha y presenta.

Dataset de cada grupo

Entrad en la ficha y descargad el recurso marcado como CSV. La primera línea del fichero os dice el separador.

Grupo	Tema	Dataset
1	Turismo	Declaraciones de Interés Turístico en Andalucía
2	Empleo	Ofertas de empleo público de Educación
3	Transporte	Puntos de venta del Consorcio de Transportes de la Bahía de Cádiz
4	Medio ambiente	Banderas azules
5	Población	Municipios. El CSV directo usa `|` y coma decimal; la llamada está en la chuleta. Hay un JSON con los mismos datos (`format=json`).

Ficha del grupo

Grupo: 4 Dataset: Banderas Azules

Papel	Nombre
Fuente	José María López González
Carga	Lucas Faura Martín
Transformación	Sergii Butrii Jose Maria
Cierre	Samuel Márquez Ruiz

Organismo que publica el dato: Junta de Andalucia

Licencia (cópiala del portal): Reconocimiento 4.0 Internacional (CC BY 4.0)

Formato descargado: CSV Filas: 634 Columnas: 5

Separador usado en `sep`: ; Codificación: cp1250

Columnas con nulos:

La columna "Notas" tiene valores nulos.

Transformación 1. Qué habéis hecho y qué ha salido:

Se limpiaron los nombres de las columnas para eliminar espacios innecesarios y se eliminaron los registros duplicados.

Transformación 2.

Se eliminó la columna "Notas" por ser innecesaria y se corrigió el nombre de la columna "Año" para llamarla "Año".

Transformación 3.

Se separó la columna Año en dos columnas numéricas independientes (Año inicio y Año final) y, finalmente, se ordenó el dataframe agrupando por provincia y año de inicio.

Para qué serviría este dato (una frase, la que diréis al presentar):

El dato serviría para analizar la evolución de la calidad de las playas de Andalucía a lo largo del tiempo, facilitando la toma de decisiones en planificación turística y conservación costera.

Orden de presentación: grupo 1, 2, 3, 4 y 5. Cuatro minutos: fuente, una transformación y la frase.